Григорий Безруков

Data Scientist (NLP, LLM, поиск)

Москва | +7 915 125-22-26 | bezgrisa@gmail.com | t.me/bezGriga | github.com/GrishaTS | hf.co/bezGriga

1,5 года коммерческой ML-разработки: поиск и ранжирование, NLP, LLM-агенты, распознавание речи, компьютерное зрение. Довожу модели до прода: от исследования данных и выбора модели до API, мониторинга качества и переобучения. Студент 4 курса ФКН ВШЭ, «Программная инженерия».

Опыт работы

ML Engineer апрель 2026 – н. в.
fodd, проектный договор *удалённо*

Сопоставление строк строительных смет со справочником работ из 5 651 позиции. Смета на один дом содержит около 10 тыс. строк. Единственный разработчик, проект с нуля.

- Сократил обработку сметы с 1–2 недель работы четырёх человек до 1–2 дней одного: 70% строк сервис проставляет сам, остальные специалист проверяет по подсказкам top-5.
- Довёл top-1 на нижнем уровне справочника до 85,1% (top-5 95,4%): каскад по уровням, bi-encoder (ANCE) с hard negatives и listwise-реранкер, выбор из 13 моделей.
- Закрыл верхние уровни связкой BM25 + LogReg (top-1 88,7% на 55 752 строках) и гибридом BM25 с bi-encoder через RRF (78,6%). LLM-реранкеры проиграли им 15–37 п. п.
- Откалибровал уверенность модели: 72,7% строк верхнего уровня проходят без человека при precision от 99%.
- Вывел в прод: FastAPI, ML-воркер с очередью в PostgreSQL, Qdrant, REST API для 1С. Модели дообучаются на подтверждённой разметке и выкатываются через blue-green без простоя.
- Построил оценку качества на эталонном наборе с доверительными интервалами и MLflow. Нашёл через сервис ошибки в разметке заказчика, их исправили.
- *Стек:* Python, PyTorch, scikit-learn, pandas, NumPy, BM25, TF-IDF, bi-encoder, cross-encoder, LLM, Qdrant, FastAPI, PostgreSQL, SQLAlchemy, APScheduler, Docker, MLflow, pytest, Git, GPU

ML Engineer апрель 2025 – май 2026
Фриланс в команде senior ML-инженера, заказчики под NDA; основной разработчик, проекты с нуля *удалённо*

Диалоговый поиск по видеоархиву декабрь 2025 – май 2026

Чат-агент вместо сложного интерфейса фильтров в системе видеоаналитики. Систему ставят в разных городах и странах, агент работает в проде.

- Сделал LangGraph-агента: превращает фразу «Иванов на Ленина 10 за январь» в запрос к API видеоаналитики, ищет людей, транспорт и адреса в Qdrant, уточняет неоднозначности в диалоге. Отдельно собрал вариант на MCP.
- Развернул сервисы в Kubernetes со Spark и CI на GitHub Actions: FastAPI, PostgreSQL, Redis, MinIO, TEI, vLLM, фронтенд на Vue 3.
- Сделал MVP поиска моментов в видео по тексту: Recall@5 0,92 по видео и 0,93 по моментам на QVHighlights. Сравнил Qwen3-VL-Embedding, CLIP, X-CLIP и Moment-DETR.
- Проверил VLM-реранкеры: Gemini Flash поднял Hit@1 с 0,43 до 0,46 и Moment Recall@5 с 0,61 до 0,64 на 107 запросах.
- *Стек:* Python, LangGraph, LangChain, MCP, LLM, vLLM, TEI, multilingual-e5, Qdrant, FAISS, PyTorch, Qwen3-VL, CLIP, FastAPI, PostgreSQL, Redis, MinIO, Vue 3, Docker, Kubernetes, Spark, GitHub Actions, pytest, MLflow

Анализ видеозаписей на признаки коррупции сентябрь 2025 – февраль 2026

Proof of concept. Аналитик смотрит около получаса отобранных фрагментов вместо 5 часов записи.

- Построил пайплайн: шумоподавление, диаризация (DiariZen), распознавание речи и три LLM-этапа: поиск маркеров, классификация реплик, оценка риска от 0 до 5.
- Выбрал GigaAM-v3 из 12 ASR-моделей и сервисов: WER 0,62 против 0,81 у Whisper на зашумлённых записях.
- Добавил видеоанализ: детекция предметов (YOLO, Gemma 3), дубли сцен, отвод камеры, затемнения.
- *Стек:* Python, PyTorch, torchaudio, GigaAM, Whisper, pyannote, LLM, vLLM, Ollama, LangChain, промпт-инжиниринг, YOLOv8, OpenCV, FastAPI, Streamlit, MongoDB, MinIO, Label Studio, Docker

Классификация обращений в техподдержку апрель 2025 – февраль 2026

Автоматическое распределение заявок в техподдержку по услугам каталога и поиск похожих заявок.

- Собрал классификатор: kNN по эмбеддингам multilingual-e5-large в Qdrant и реранкер bge-reranker-large, weighted F1 до 0,87.
- Сократил 290 категорий до 26 частых по итогам анализа ошибок, настроил переобучение по расписанию.
- Выбрал Qdrant вместо Milvus по бенчмарку на 100 тыс. эмбеддингов: он быстрее.
- Разметил с помощью LLM без обучения (Qwen 2.5, Ollama) 9 900 сообщений чата финтех-приложения по 24 интентам: обучающая выборка без ручной разметки.

- *Стек:* Python, Hugging Face Transformers, multilingual-e5-large, bge-reranker, TEI, Qdrant, Milvus, FAISS, scikit-learn, pandas, LLM, Ollama, FastAPI, Streamlit, Docker

Авторазметка изображений для Label Studio май – ноябрь 2025

Предразметка изображений моделями для команды разметки заказчика, около 20 человек.

- Ускорил разметку примерно в 4 раза: модели предлагают рамки, маски и текст, разметчики правят или подтверждают. Со временем почти вся работа сводится к подтверждению.
- Подключил YOLOv8 с дообучением на новой разметке, SAM, Florence-2, Qwen2.5-VL и Tesseract для детекции, сегментации и OCR.
- *Стек:* YOLOv8, SAM, Florence-2, Qwen2.5-VL, Tesseract, Ollama, Label Studio, MinIO, MLflow, FastAPI, Docker

Учебные проекты

Поиск фотографий по тексту на русском | *ruCLIP, FastAPI, Qdrant, PostgreSQL, MinIO, Docker* 2025

- Курсовая. Дообучил ruCLIP и выложил веса на Hugging Face. Собрал датасет изображений с подписями от Qwen 2.5, сравнил с OpenCLIP.

Соревнования курса «Скоринговые модели» ВШЭ на Kaggle | *CatBoost, LightGBM, Optuna, pandas*

- Топ-3 в 4 соревнованиях: цены квартир, банкротство компаний, больницы, маркетинг.

Образование

НИУ ВШЭ, факультет компьютерных наук 2023 – 2027
Бакалавриат, «Программная инженерия», 4 курс *Москва*

- Курсы: машинное обучение, глубокое обучение, инженерия данных, базы данных, скоринговые модели, архитектура Big Data, SRE (T-Академия: Kubernetes, мониторинг, SLO).

Навыки

Языки: Python, SQL, C++, английский B2
Математика: линейная алгебра, аналитическая геометрия, математический анализ, дискретная математика, теория вероятностей, математическая статистика, алгоритмы и структуры данных, A/B-тесты
ML: scikit-learn, CatBoost, LightGBM, XGBoost, pandas, NumPy, SciPy, EDA, feature engineering, SHAP, временные ряды
DL: PyTorch, Hugging Face Transformers, трансформеры, bi-encoder, cross-encoder, файнтюнинг, CNN
LLM: LLM-агенты, LangGraph, LangChain, MCP, tool calling, RAG, промпт-инжиниринг, vLLM, Ollama, оценка качества LLM
Поиск: Qdrant, Milvus, FAISS, BM25, эмбеддинги, ранжирование
NLP, CV, речь: NLP, YOLO, SAM, OCR, OpenCV, ASR (GigaAM, Whisper), VLM
Прод и данные: FastAPI, REST API, Docker, Kubernetes, Spark, Airflow, ETL, PostgreSQL, ClickHouse, Redis, MongoDB, MinIO, MLflow, Grafana, Git, CI/CD, pytest, Linux, BeautifulSoup, Power BI